

Relatório CARD 20 - Prática: Reconhecimento de Emoções com TensorFlow 2.0 e Python (III)

Willian Augusto Soder de Souza

O objetivo deste relatório é apresentar os principais conhecimentos adquiridos ao assistir ao curso 'Reconhecimento de Emoções com TensorFlow 2.0 e Python'. O apresentador começa mostrando exemplos práticos de códigos de redes neurais que realizam a detecção de emoções e, em seguida, apresenta conceitos teóricos. Abaixo segue um resumo dos principais pontos abordados na parte prática, seguido por uma lista dos principais conhecimentos teóricos apresentados.

No início do curso, o apresentador carrega uma rede neural já treinada, prepara uma imagem convertendo-a para tons de cinza e extraindo a região de interesse (face), e realiza o teste do detector de emoções. Em seguida, ele apresenta a arquitetura de um modelo de rede neural para a mesma tarefa, que obteve a maior acurácia em uma competição do Kaggle. No entanto, no teste, o modelo não atingiu a mesma acurácia que na competição. O apresentador explica a arquitetura desse modelo passo a passo e também mostra mais cinco arquiteturas dessa competição. Este curso foi essencial para entender e fixar a arquitetura de uma rede neural, pois o apresentador explica detalhadamente cada ponto e variável da rede.

Abaixo segue uma lista dos principais conceitos teóricos apresentados na seção 4.

- **Perceptron de uma camada:** é a forma mais básica de rede neural artificial. Ele recebe várias entradas, multiplica cada uma por um peso, soma esses valores, e passa o resultado por uma função de ativação que decide a saída (geralmente 0 ou 1). É usado para problemas de classificação linearmente separáveis, mas tem limitações para resolver problemas mais complexos. Durante o treinamento, os pesos são ajustados para melhorar a precisão da saída com base nos exemplos de treinamento.
- **Função de soma:** é um dos componentes principais de um neurônio artificial. Ela realiza a tarefa de combinar todas as entradas recebidas pelo neurônio em um único valor antes de passar esse valor para a função de ativação.
- **Função de ativação:** é um componente das redes neurais que determina a saída de um neurônio artificial, dado o valor calculado pela função de soma. Ela introduz não-linearidade no modelo, permitindo que a rede aprenda e represente padrões complexos.
- **Cálculo do erro:** é um processo fundamental no treinamento de modelos, pois mede a diferença entre a saída prevista pela rede e a saída real ou desejada. Esse erro orienta o ajuste dos pesos da rede para melhorar sua precisão e capacidade de generalização.
- **Descida do gradiente:** é um algoritmo de otimização fundamental usado em redes neurais para ajustar os pesos da rede a fim de minimizar a função de custo ou perda. O objetivo principal da descida do gradiente é encontrar o conjunto de pesos que resulta no menor erro possível, ou seja, o melhor desempenho da rede.
- **Descida do gradiente estocástica (SGD):** é uma variação do algoritmo de descida do gradiente usado para otimizar redes neurais e outros modelos de aprendizado de máquina. A principal característica da SGD é que ela atualiza os pesos do modelo usando um único exemplo de treinamento por vez, ao invés de usar todo o conjunto de dados de uma vez.

- **Parâmetro delta:** é uma medida usada durante o treinamento de uma rede neural para ajustar os pesos de um neurônio. Ele é parte crucial do processo de retropropagação, que é a técnica padrão para treinar redes neurais.
- **Backpropagation:** é o algoritmo que ajusta os pesos de uma rede neural, utilizando a derivada da função de custo em relação aos pesos para atualizar os pesos na direção que mais reduz o erro. Esse processo é essencial para que a rede neural aprenda a partir dos dados e melhore seu desempenho ao longo do tempo.
- **Bias:** é um parâmetro adicionado à soma ponderada das entradas de um neurônio em uma rede neural. Ele permite que o neurônio ajuste sua saída de forma mais flexível, mesmo quando todas as entradas são zero. O bias é essencial para aumentar a capacidade do modelo de aprender e se adaptar a padrões complexos, melhorando o desempenho geral da rede neural.

CONCLUSÃO:

Este card foi muito importante para o entendimento de Redes Neurais Artificiais, pois o apresentador, ao explicar a arquitetura da rede, deu ênfase significativa aos parâmetros das funções e ao pré-processamento das imagens para a rede. Além disso, a compreensão dos conceitos teóricos de redes neurais é fundamental para o sucesso no desenvolvimento e aprimoramento de modelos de aprendizado de máquina. A teoria fornece o contexto necessário para a prática, possibilitando uma abordagem mais informada e eficaz no treinamento e na aplicação de redes neurais.